

발전 로드맵

실행 통제 MVP → 내부 신호의 추가 효과 → 제한된 고객 파일럿 → 검증된 확장
Commercial Delivery / Research Milestones

01 이번 개정의 우선순위

고객 업무를 하나로 좁히고 정책 기반 실행 통제를 먼저 연결한다. 동시에 C가 Activation 연구를 진행한다. 기본 제품과 연구를 분리해 Probe 성능이 불확실해도 정상적인 보안 실행 경로를 완성한다.

구분	목표 / 완료 증거
제품 트랙	문서 검색·보고서·모의 발송 업무에서 정책, 승인, 실행·로그 연결
연구 트랙	E2: 정책+문맥 대비 E3: Activation 추가의 실측 효과
고객 트랙	문제·연동 조건·파일럿 의향의 인터뷰 근거
포트폴리오 트랙	C의 표현 분석·Probe-OOD·실패 분석과 PR/실험 증거
기간	2026.09.22 ~ 10월 마지막 주. 개발 목표 마감 10/18, 제출 초안 10/25

02 마일스톤과 연구 Phase 구분

M0~M5는 이번 5주 내외의 제품·팀 실행 일정이다. 기존 Phase 1~6는 연구 성장 단계로 유지한다. Phase 1~2를 이번 일정에 연결하고, Phase 3 이후는 검증 결과에 따라 별도로 추진한다.

03 이번엔 하지 않을 것

강화학습 Red Agent, 자동 재학습·Adaptive Monitoring, 범용 SaaS, 결제, 다수 프레임워크 연동은 후속 과제다. 광범위한 블록 내부 분석과 CV 확장은 필수 결과를 대체하지 않는다.

주차별 실행 계획

첫 주에 인터페이스를 고정하고 예제 데이터로 병렬 개발한다. A가 공통 시스템을 맡되 B·C·D가 각 영역의 코드를 직접 구현한다.

기간	팀 작업 / 완료 기준
M0 · 9/22~9/27	A: Guard 골격·모델 실행 / B: 최소 문서·발송 환경 / C: hook·표현 명세 / D: 공통 로그·평가 명세. 한 행동을 검사·기록하고 Activation과 연결.
M1 · 9/28~10/4	A: 정책·승인 연결 / B: 정상·위험 데이터 / C: Linear Probe baseline / D: E0~E2 기준선·인터뷰 착수. 정책만으로 차단·승인 데모와 첫 탐지 결과.
M2 · 10/5~10/11	A: 통합·실행 우회 점검 / B: 시나리오 다양화 / C: Single·Top-3·All 및 시점 비교 / D: Validation 운영 지표. E3 평가 설정·채택 기준 고정.
M3 · 10/12~10/18	A: 승인 재검사·안정화 / B: held-out 라벨 검수 / C: 고정 모델 제출·오류 분석 / D: OOD 최종 평가·E0~E3 비교. 통합 데모와 핵심 결과 확보.
M4 · 10/19~10/25	재현 실행, 실패 사례, 고객 검증 결과, 개인 기여 문서 작성. 안정성 확보 시에만 별도 ViT 소규모 실험. 제출 가능한 초안 완성.
M5 · 10월 마지막 주	새 기능 추가보다 재현 확인·영상·발표 연습·최종 제출. 계획과 실측 성과를 분리해 공개.

04 주간 운영

주 1회 함께 재현 가능한 데모를 확인하고, 미완료 원인을 Issue로 남긴다. 실험은 설정·결과·PR을 연결한다. GPU 작업은 공통 수집 일정을 잡고 C의 반복 학습은 저장된 특징을 활용한다.

기한은 팀 목표안이며 학교 제출일이 확정되면 마지막 주를 조정한다. 실제 GPU 사용 가능 시간과 수집량은 M0 실측 후 확정한다.

진입·중단 기준과 의존성

기능의 수보다 증거와 안정성을 기준으로 다음 단계에 진입한다. 상업화는 개발 완료만으로 확정되는 결과가 아니다.

점검 시점	통과 기준 / 미달 시 조치
9/27 · 실행 경로	Guard를 거치지 않은 실행이 없고 한 실행의 로그·라벨·표현이 정렬됨. 미달 시 모델·도구·시나리오 수를 줄인다.
10/4 · 기준선	정책 차단·승인 데모, E0~E2와 Probe 첫 결과. 신호가 약하면 라벨·시점·편향 점검, 복잡한 모델 추가 보류.
10/11 · 설정 고정	Validation으로 레이어·임계값·지연 예산·정상 업무 기준을 고정. 독립 Test는 조정에 사용하지 않는다.
10/18 · 제품 판단	E3의 추가 효과와 운영 부담을 함께 확인. 개선 없으면 Activation을 실험 기능으로 남기고 기본 Guard 결과를 보고한다.
10/25 · 제출 준비	재현 절차, 실패 분석, 영상·보고서 초안 완료. CV·새 기능 때문에 이 기준을 미루지 않는다.

05 협업 인터페이스

- A→B: 도구 실행 인터페이스·신뢰된 권한 전달. B→C/D: 시나리오·행동 라벨과 split 메타데이터.
- C→A: 모델별 adapter, Probe 버전·점수·유효성. C→D: 고정된 모델과 학습·선택 설정.
- D→팀: 공통 지표·결과 형식, 최종 평가 실행, 회귀·정상 업무 검증.

06 장애·위험 관리

내부 접근 불가 모델은 Activation 미지원으로 표시한다. 필수 검사 실패 시 고위험 실행은 보류하고, 선택적 Probe 오류는 기록하면서 기본 정책을 유지한다. 명시적 정책 차단은 점수로 해제하지 않는다. 승인된 인자 변경·재사용·중복 실행을 점검한다.

C: 표현 분석과 보안 연구

담당: ljl5489. 연구 질문 설계부터 구현·실험·한계 분석까지 일관된 오너십을 확보한다. D가 독립 평가를 지원한다.

작업 패키지	구현·분석 / 남길 증거
C-01 · 표현 추출	블록·토큰별 hook, feature 저장·메타데이터, alignment 확인. adapter 코드·명세·A와 통합 PR.
C-02 · Probe 기준선	Linear Probe와 동일 조건의 레이어 비교. seed-split·학습 설정·모델 artifact 식별값.
C-03 · 감시 지점·시점	Single / Top-3 / All, 조기 예측 / 실행 직전 판별. 성능·지연 곡선과 선택 근거.
C-04 · 보안·OOD 분석	위협 유형·미지 시나리오별 평가, 오탐·미탐 사례, E2 대비 E3 ablation. D의 고정 평가 결과로 분석.
C-05 · 선택 CV 확장	별도 ViT 특징 probing·이미지 분포 변화 실험. 데이터·평가 분리·결과 노트북. 10/18 안정성 조건 충족 시에만 착수.

07 포트폴리오에 남길 근거

문제: 왜 행동 문맥만으로 부족한가? 설계: 어떤 표현과 시점을 왜 선택했는가? 구현: 어떤 adapter·Probe 코드를 작성했는가? 검증: E2 대비 추가 효과, OOD와 실패 조건은 무엇인가? 한계: 비용·모델 의존성·데이터 편향을 어떻게 확인했는가?

08 CV 역량의 정직한 연결

LLM 실험은 표현 학습 분석과 AI 보안 경험으로 제시한다. CV 실적은 실제 이미지 실험을 수행한 뒤에만 적는다. ViT 후속 실험은 LLM Probe의 직접 전이가 아니라 공통 feature 추출·probing 방법론의 재적용이며, OOD를 곧바로 공격·위험 라벨로 취급하지 않는다.

미관상 임베딩 군집이 분리된 그림만으로 일반화 성능이나 인과관계를 주장하지 않는다. 핵심 근거는 통제된 비교, held-out 지표, 실패 사례와 재현 코드다.

장기 발전과 파일럿 판단

이번 MVP의 결과와 고객 요구를 바탕으로 확장한다. 내부 감시는 선택 기능이며, 고객 가치가 확인된 범위부터 고도화한다.

연구 단계	진행 조건과 결과
Phase 1 · Probe	위험 신호의 존재·시간적 선행성과 누수 없는 기준선 확인. M1~M2 연결.
Phase 2 · 강건성·효율	다중 지점·OOD에서 E2 대비 E3의 추가 효과와 비용 확인. M2~M3 연결.
Phase 3 · 실패 탐색	기본 비교·Gate 안정화 후 시나리오 변형·탐색부터 시작. RL은 단순 탐색 대비 필요성 확인 후.
Phase 4 · 재학습	독립 검증된 실패만 추적. 버전 비교, 회귀 검사와 롤백을 갖춘 경우 진행.
Phase 5 · 적응 감시	정적 감시 대비 비용·위험 감소가 있을 때 레이어·강도 선택 정책 연구.
Phase 6 · 제한적 개선	변경 가능한 Probe·임계값·정책 후보 범위 고정. 최종 권한 정책·독립 평가·승인 기준은 개선 루프 외부에 유지.

09 제품 파일럿으로 넘어가는 조건

고객이 겪는 구체적 문제와 도구 연동 지점이 확인되고, 보안 검사·승인·로그를 해당 환경에서 검증할 수 있어야 한다. 고객별 지연·운영 부담·배포·보관 요구를 합의한다. Activation 접근이 불가능하면 기본 Guard만 검증하며 내부 감시를 약속하지 않는다.

10 후속 연구 순서

실제 이미지 기반 ViT 실험 → 필요 시 VLM의 이미지 지시·문서 공격 평가 → 별도 모델 일반화. 인과 분석은 관찰 실험과 구분한 개입 실험으로 추진한다. 결과 없는 상태에서 더 강한 모델 지원이나 완전한 안전성을 주장하지 않는다.

참조: 동시 개정한 Argus-V 프로젝트 기획서 v2.0. 모든 일정·역할·지표는 계획이며, 실험·고객 검증 결과는 실행 후 별도로 기록한다.